

Московский государственный университет имени М.В. Ломоносова
Факультет вычислительной математики и кибернетики

Формальные языки и автоматы
Методичка для сдающих и пересдающих

Может, зайдет кому-нибудь

Оглавление

1	Немного теормина	4
2	НКА по РВ	5
2.1	Алгоритм	5
2.2	Почему это работает	6
3	ДКА по НКА	7
3.1	Алгоритм	7
3.2	Почему это работает	10
4	ДКА по РВ	11
4.1	Алгоритм	11
4.2	Почему это работает	15
5	Минимизация ДКА	16
5.1	Алгоритм	16
5.2	Почему это работает	19
6	Отрицание, пересечение и объединение автоматов	20
6.1	Алгоритм	20
6.2	Отрицание	21
6.3	Почему это работает	21
6.4	Пересечени и объединение	22
6.5	Почему это работает	24
7	Построение автомата по праволинейной грамматике	25
7.1	Алгоритм	25
7.2	Почему это работает	26
8	Приведение КС-грамматики	27
8.1	Алгоритм удаления бесплодных символов	27
8.2	Почему это работает	28
8.3	Алгоритм удаления недостижимых символов	28

8.4	Почему это работает	29
8.5	Алгоритм удаления ϵ -правил	29
8.6	Почему это работает	29
8.7	Алгоритм удаления левой рекурсии (примитивной)	30
8.8	Почему это работает	30
8.9	Алгоритм удаления левой факторизации	31
8.10	Почему это работает	31
9	Построение LL(1)-анализатора	32
9.1	Почему это работает	34
9.2	Алгоритм разбора цепочки с помощью LL(1)-анализатора	35
10	Построение LR(1)-анализатора по КС-грамматике	36
11	Лемма о накачке	37

Предисловие

Однажды я сдавал формалки. Не самый приятный опыт в моей жизни. Когда я ждал результатов, я сказал, что если не сдам, напишу методичку по этому чудесному предмету.

Как несложно догадаться, я тогда не сдал.

По формалкам уже есть отличное руководство в виде решений задач от Тани (не знаю, кто это, но если бы ее не было, статистика сдаваемости была бы гораздо хуже, я уверен, Таня, спасибо, что ты есть), и казалось бы - зачем я это делаю?

Ну во-первых, я сказал, что напишу.

Во-вторых, это довольно знатный способ подготовки к пересдаче, который потенциально поможет каким-нибудь людям после меня.

В-третьих, наверное, есть смысл восполнить пробел в нормальном "печатном" пособии по формальным языкам. Ахо Ульмана я не читал (а он, может быть, и норм), но "Теорию Построения Компиляторов" читать совершенно невозможно.

В этой методичке я в меру своих возможностей постараюсь не только подробно расписать решения различных задач (это уже есть у Тани), но и более-менее человеческим языком расписать, как применяемые алгоритмы работают (потому что выучить алгоритм, если есть примерное понимание работы, гораздо проще)

За кривой русский язык извиняйте - я ЕГЭ сдал на 30 баллов.

Глава 1

Немного теормина

Недетерменированный конечный автомат - НКА

Глава 2

НКА по РВ

2.1 Алгоритм


Построение НКА по РВ делается по определенным правилам

Каждое РВ можно разбить на подвыражения, а для простейших подвыражений автомат строится довольно просто


На рисунке далее

1. Е-переход
2. Переход по символу a
3. Переход по $a|b$ (a или b)
4. Переход по ab (сначала a , потом b)
5. Переход по a^* (сколько угодно символов a , в т.ч. 0)

Справа от простейших НКА нарисованы общие НКА, когда переход совершается по некоторому РВ, где r - РВ, а $M(r)$ - НКА, построенный по нему.



На рисунке изображено построение НКА для РВ $b(a|ba)^*|aab$



2.2 Почему это работает

Правильность таких построений довольно очевидна, но если не верится, можно походить по полученным НКА по дугам и убедиться, что ничего кроме того, что описано в РВ, по ним составить нельзя.

Глава 3

ДКА по НКА

Глядя на НКА, полученные по РВ может показаться, что там слишком много лишних ϵ -переходов, и они бесят. Также НКА это вам не ДКА: есть неопределенности которые бесят (хотя процесс детерминирования бесит больше). В любом случае существует алгоритм, позволяющий из большого, но красивого НКА получить маленький и очень некрасивый ДКА.

3.1 Алгоритм

Введем некоторые обозначения:


1. $\epsilon\text{-closure}(R)$ (эпсилон-замыкание состояния R) - множество состояний, в которые можно попасть из состояния R по символу ϵ . Стоит отметить, что "скачков" может быть больше одного, то есть, если в состояние Q можно попасть из P по ϵ , а из Q можно по ϵ попасть в R , то $R \in \epsilon\text{-closure}(P)$. На языке умных людей это называется транзитивностью, но я тут не сложными словами щеголять пришел.

2. $\text{move}(R, a)$ (достижимые из R по a) - множество состояний, в которые можно попасть из состояния R по символу a . (тут скачок должен быть только один)

В качестве примера рассмотрим уродца из предыдущей главы:

$b(a|ba) * |aab$

1. Для начала все состояния надо пронумеровать



Далее мы начинаем описывать новый автомат с новыми состояниями - тут уже традиционно используют заглавные латинские буквы. Каждое новое состояние описывается множеством старых состояний из первого автомата.

2. В качестве начального состояния нового ДКА берут $A = e\text{-closure}(1)$, в нашем случае это $A = \{1, 2, 11\}$.

3. Далее формируются следующие правила переходов:

$$D(A, a) = \text{move}(A, a) + e\text{-closure}(\text{move}(A, a))$$

$$D(A, b) = \text{move}(A, b) + e\text{-closure}(\text{move}(A, b))$$

И т.д.

Пусть вышло так, что есть состояние Q , из которого по символу b мы переходим в состояние, описываемое множеством $\{1, 2, 3, 4, 6, 8, 12, 23\}$. При этом, если у такого множества уже есть имя, например W , то это попросту значит, что $D(Q, b) = W$. Если такого множества раньше не встречалось, то оно добавляется в таблицу состояний нового ДКА.

Звучит сложно и скучно, поэтому лучше посмотреть на живой пример.

$$A = \{1, 2, 11\};$$

$$\text{move}(A, a) = \text{move}(1, a) + \text{move}(2, a) + \text{move}(11, a);$$

$$\text{move}(A, a) = \{\} + \{\} + \{12\} = \{12\};$$

$$e\text{-closure}(\text{move}(A, a)) = \{\};$$

$$D(A, a) = \text{move}(A, a) + e\text{-closure}(\text{move}(A, a)) = \{12\} + \{\} = \{12\};$$

Состояния $\{12\}$ у нас еще не было, поэтому добавим его в таблицу состояний и назовем его B .

Проделаем аналогичные выкладки для символа b .

$$\text{move}(A, b) = \text{move}(1, b) + \text{move}(2, b) + \text{move}(11, b);$$

$$\text{move}(A, b) = \{\} + \{3\} + \{\} = \{3\};$$

$$e\text{-closure}(\text{move}(A, b)) = \{4, 5, 7, 8, 15\};$$

$$D(A, b) = \text{move}(A, b) + e\text{-closure}(\text{move}(A, b)) = \{3\} + \{4, 5, 7, 8, 15\} = \{3, 4, 5, 7, 8, 15\};$$

Состояния $\{3, 4, 5, 7, 8, 15\}$ у нас тоже еще не было, поэтому запишем его в таблицу состояний ДКА.

Подобные вычисления надо проводить для каждого символа в алфавите, для каждого

нового состояния в таблице до тех пор, пока все старые состояния не будут описаны. С виду может показаться, что это очень много писанины, но на деле все эти преобразования делаются в уме и единственное, что нужно реально выписывать, это таблицу состояний.

Привожу финальную таблицу переходов для НКА из предыдущей главы.


	<i>a</i>	<i>b</i>
$A\{1, 2, 11\}$	<i>B</i>	<i>C</i>
$B\{12\}$	<i>D</i>	\times
$*C\{3, 4, 5, 7, 8, 15\}$	<i>F</i>	<i>G</i>
$D\{13\}$	\times	<i>E</i>
$*E\{14, 15\}$	\times	\times
$*F\{4, 5, 6, 7, 8, 15\}$	<i>F</i>	<i>G</i>
$G\{9\}$	<i>H</i>	\times
$*H\{4, 5, 7, 8, 10, 15\}$	<i>F</i>	<i>G</i>

Внимательный читатель заметит, что некоторые состояния отмечены звездочками и спросит, что это. Отвечаю: звездочками помечены конечные состояния. И это следующее правило алгоритма построения:

4. Конечными состояниями нового ДКА помечаются такие состояния, которые содержат в себе конечное состояние старого НКА.

В данном случае старым конечным состоянием является 15, поэтому все состояния, имеющие в себе 15 становятся конечными.

На рисунке изображен полученный ДКА.



3.2 Почему это работает

Работа алгоритма строится на двух мыслях:

1. Если из одного состояния по e можно перейти в несколько других, то зачем нам эти другие состояния, если по сути состояние одно, просто разбитое на несколько частей? (незачем)

Грубо говоря, мы стягиваем за e -дуги много состояний в одно, как за веревки.

2. Если после стягиваний состояний, две дуги, раньше шедшие в два разных состояния, теперь идут в одно стянутое, то действительно ли между этими дугами есть разница? (нет)

Глава 4

ДКА по РВ

Допустим, что у нас есть РВ, которое необходимо преобразовать в ДКА. И казалось бы, уже есть целых 2 алгоритма, с помощью которых это можно сделать: сначала строим НКА, потом по нему же ДКА. Но есть более быстрый алгоритм прямого перевода.

4.1 Алгоритм

Для начала возьмем все то же РВ из первой главы $b(a|ba) * |aab$


1. Строим расширение РВ: просто дописываем в конце символ конца, как бы странно это не звучало. Получаем $(b(a|ba) * |aab)\#$

2. Нумеруем все буквы в нашем РВ (в том числе и символ конца)

$(b(a|ba) * |aab)\#$

1 2 34 567 8

3. Строим дерево РВ (обязательно помним про приоритеты операций)



4. Теперь пошла жара: надо определить кучу разных множеств для поддеревьев:

$nullable(s)$ - обнуляемость: может ли поддереву s породить пустую цепочку

Тут несколько вариантов:

s - лист дерева: $nullable(s) = false$

$s = p*$, где p - некоторое поддереве: $nullable(s) = true$

$$s = p \mid q: \text{nullable}(s) = \text{nullable}(p) \text{ or } \text{nullable}(q)$$
$$s = p \bullet q: \text{nullable}(s) = \text{nullable}(p) \text{ and } \text{nullable}(q)$$

$firstpos(s)$ - первый символ: множество символов, которые могут идти первыми в цепочке, порожденной поддеревом s

s - лист дерева: $firstpos(s) = \{s\}$

$$s = p*: firstpos(s) = firstpos(p)$$
$$s = p \mid q: firstpos(s) = firstpos(p) \cup firstpos(q)$$
$$s = p \bullet q: \text{если } nullable(p), \text{ то } firstpos(s) = firstpos(p) \cup firstpos(q), \quad \text{иначе}$$
$$firstpos(s) = firstpos(p)$$

$lastpos(s)$ - последний символ: множество символов, на которые может заканчиваться цепочка, порожденная поддеревом s

s - лист дерева: $lastpos(s) = \{s\}$

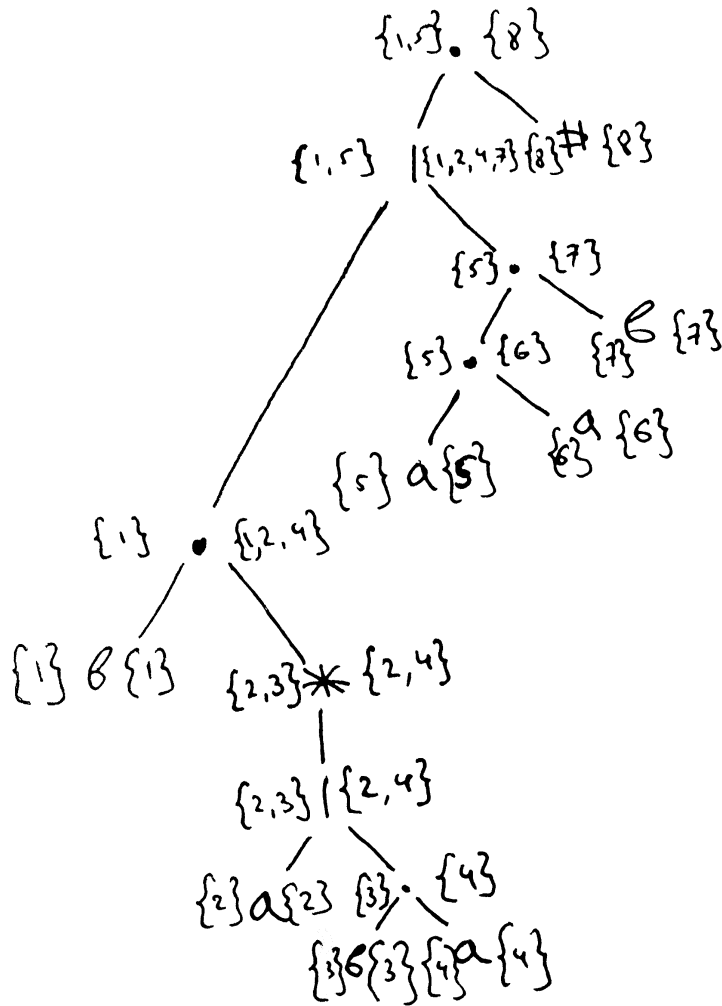
$$s = p*: lastpos(s) = lastpos(p)$$

$s = p \mid q: lastpos(s) = lastpos(p) \cup lastpos(q)$
 $s = pq: \text{если } nullable(q), \text{ то } lastpos(s) = lastpos(p) \cup lastpos(q), \quad \text{иначе}$
 $lastpos(s) = lastpos(q)$

На самом деле все это страшно скучная херня и по большей части решается с помощью метода пристального взгляда и более-менее здравого смысла.

Теперь можно пояснить и за странные пометки в предыдущем рисунке: слева стояли $firstpos(s)$, а справа - $lastpos(s)$

Сейчас прошлый рисунок будет дополнен аналогичными множествами, но уже не только для листьев.



5. Жара продолжается: теперь надо вычислить $followpos(s)$ - множество символов, которые могут идти прямо после цепочки, порожденной поддеревом s .

Здесь строгие алгоритмы выглядят еще скучнее, чем для прошлых множеств, но метод пристального взгляда по-прежнему здесь справляется довольно неплохо (хотя иногда и допускает ошибки: мой вот пристальный взгляд в свое время накосячил, а теперь я пишу эту методичку).

Но в любом случае, вот алгоритм:

Для $p \bullet q$: для каждого $i \in lastpos(p)$ добавить $firstpos(q)$ в $followpos(i)$

Для p^* : для каждой позиции $i \in lastpos(p)$ добавить $firstpos(p)$ в $followpos(i)$

Если первое правило вполне понятно, то второе уже посложнее. Оно становится понятнее, если напомнить себе, что из p^* может получиться цепочка pp . Тогда все встает на свои места (потому что явным образом видно, что за всеми $lastpos(p)$ спокойно могут идти любые символы из $firstpos(p)$). Осознавая это, вы, наверное, не накосячите так, как однажды это сделал я.

Для нашего дерева получается такая таблица:

<i>symbol</i>	<i>followpos(symbol)</i>
1	{2, 3, 8}
2	{2, 3, 8}
3	{4}
4	{2, 3, 8}
5	{6}
6	{7}
7	{8}
8	{}

6. Строим таблицу переходов. Состояния здесь описываются множествами, как и в прошлой главе. За начальное состояние A берется множество $firstpos$ (корень дерева). Дальше правила переходов описываются следующим образом:

$$D(Q, s) = \bigcup_{i=Q \cap s} followpos(i)$$

Сложная формула, за которой хрен пойми какая логика стоит, поэтому рассмотрим на живом примере:

В данном случае наше стартовое состояние $A = \{1, 5\}$.

Символ $a = \{2, 4, 5, 6\}$ (множество цифр, которые в пронумерованном РВ стоят под символом a)

Пересекая множества a и A получим $\{5\}$. $followpos(5)$ смотрим по таблице - $\{6\}$. Такого множества в качестве состояния у нас еще не было, поэтому назовем его $B = \{6\}$. Таким образом получается, что $D(A, a) = B$.


Абсолютно аналогично поступаем со всеми символами алфавита и всеми неописанными множествами. Со временем новые состояния перестанут поступать, а мы получим законченную таблицу.

Конечным состоянием объявляется то, которое в своем множестве содержит номер символа конца.

Для нашего $b(a|ba) * |aab$ получается следующая таблица:

	$a\{2, 4, 5, 6\}$	$b\{1, 3, 7\}$
$A\{1, 5\}$	B	C
$B\{6\}$	D	x
$*C\{2, 3, 8\}$	C	E
$D\{7\}$	x	F
$E\{4\}$	C	x
$*F\{8\}$	x	x

Осталось всего ничего: построить сам ДКА по таблице



4.2 Почему это работает

По сути каждое состояние описано множеством тех номеров букв, которые могут нас из этого состояния вывести. Действительно, если внимательно посмотреть на наше РВ,

$(b(a|ba) * |aab)\#$
 1 2 34 567 8

можно заметить, что выйти из начального состояния мы можем только по буквам $b1$ и $a5$. При этом те же буквы, но с другими номерами нам не подойдут. *followspos*-ы здесь тоже появляются вполне по делу: через них очень удобно описываются те номера букв, которые выводят нас из состояния, в котором мы оказались. Ведь если мы уже прошли вперед по символу $b1$, то дальше в цепочке, удовлетворяющей РВ, мы по определению сможем встретить только символ из *followpos*($b1$).

Из всех этих номеров можно построить очень простой, но здоровый автомат разбора, где алфавит нетерминалов будет состоять из чисел, которыми нумеруются буквы в исходном РВ. Просто этот большой автомат потом можно будет сократить, заменив номера, на буквы, которые им соответствуют.

Глава 5

Минимизация ДКА

Внимательный читатель мог задаться вопросом: как же так получилось, что мы взяли одно РВ, и получилось 2 разных ДКА? И почему этот второй ДКА получился таким аккуратным?


А все потому, что ДКА из НКА мы не минимизировали.

5.1 Алгоритм

1. Первым делом автомат надо дополнить, то есть, сделать так, чтобы в нем всегда было куда перейти (сделаем так, чтобы не было правил вида $D(Q, s) = \emptyset$)

Если автомат уже полный, то ничего не делаем, в противном случае добавляем новое состояние V (ну или как вы его назовете, я называю V от слова *void*, потому что это удобно), а после этого ведете в него все отсутствующие дуги (и из V в себя же по всем буквам алфавита).

В качестве примера возьмем нашего старого доброго уродца из "НКА по РВ" и дополним его:



2. Строим разбиение P_0 множеств состояний следующим образом:

$P_0 = \{F\}, \{Q \setminus F\}$, где $\{F\}$ - все конечные состояния, а $\{Q \setminus F\}$ - все остальные. В дальнейшем эти множества я буду называть группами.

А дальше строится разбиение P_1 следующим образом:

Если A и B принадлежит одной группе и по всем нетерминальным символам переходят в одну и ту же группу (не обязательно в свою), то они остаются в одной группе.

А если есть два состояния из одной группы, и по какому-то нетерминалу переходит в другую группу, то он уходит в новую группу.

И вот все эти разбиения надо продолжать до тех пор, пока не окажется, что $P_n = P_{n+1}$ (умные люди называют это стабилизацией).

Рассмотрим отдельный пример:

$P_0 = \{S\}, \{A, B, C, D\}$, при этом A, B по символу a переходят в $\{S\}$, а по b - в свою группу. C, D же по a, b переходят в свою группу. И тут можно сначала выделить отдельную группу $\{A\}$, а потом еще одну группу $\{B\}$. На самом деле группа определяется тем, что ее элементы ведут себя одинаково, а в данном случае A и B ведут себя идентично, поэтому правильнее будет выделить их вместе в отдельную группу и получить разбиение $P_1 = \{S\}, \{A, B\}, \{C, D\}$. Если вдруг выяснится, что A и B на самом деле ведут себя по-разному, то на следующих итерациях, они будут разведены по разным группам, но пока что они должны быть в одной группе. За такими удалениями разных элементов в одну группу надо внимательно следить, иначе можно получить ошибочный ответ.

А теперь мы построим разбиения на группы для нашего дополненного автомата:

При этом у каждой группы я буду ставить ее порядковый номер, а возле состояний в группе буду ставить "вектор переходов в группы". Поясню за сложное словосочетание "вектор переходов в группы": A_{03} означает, что по a мы переходим из A в группу-0, а по b - в группу-3. Так сразу становится понятно, кого надо разнести по разным группам, а кого надо оставить в одной.

$$P_0 = \{C_{01}, E_{11}, F_{01}, H_{01}\}_0, \{A, B, D, G, V\}_1$$

$$P_1 = \{C, F, H\}_0, \{E\}_1, \{A_{20}, B_{22}, D_{21}, G_{02}, V_{22}\}_2$$


$$P_2 = \{C, F, H\}_0, \{E\}_1, \{A\}_2, \{B_{43}, V_{33}\}_3, \{D\}_4, \{G\}_5$$

$$P_3 = \{C_{05}, F_{05}, H_{05}\}_0, \{E_{66}\}_1, \{A_{30}\}_2, \{B_{46}\}_3, \{D_{61}\}_4, \{G_{06}\}_5, \{V_{66}\}_6$$

$$P_4 = P_3: \text{ закончили}$$


Внимательный читатель может подумать, что я охерел и не всегда выставлял "вектор переходов в группы" у состояний. Это все банально потому, что мне очень лень. Не обязательно на одной итерации разносить по разным группам ВСЕ, что только можно. Если в одной группе есть два состояния, которые надо разносить по группам, то рано или поздно мы все равно до них доберемся и разнесем. А разнося состояния потихоньку, ниже шанс ошибки (наверное).

Осталось всего ничего: построить автомат, взяв в качестве состояний группы, и удалив бесплодные и недостижимые состояния (те, из которых нет пути в какое-нибудь итоговое состояние и те, в которые нет входящих стрелок), это вполне успешно делается методом пристального взгляда. Бесплодным состоянием как минимум является состояния, содержащее наше новое состояние V .



5.2 Почему это работает

На мой взгляд сам алгоритм говорит сам за себя, но чуть громче он будет говорить на фоне вот такого автомата:



Глава 6

Отрицание, пересечение и объединение автоматов

Отрицание автомата AVT - такой автомат \overline{AVT} , который успешно обрабатывает любую цепочку, которую не обрабатывает AVT .

Пересечение автоматов $AVT1$ и $AVT2$ - такой автомат $AVT3$, который успешно обрабатывает любую цепочку, которую успешно обрабатывает и $AVT1$, и $AVT2$.

Объединение автоматов $AVT1$ и $AVT2$ - такой автомат $AVT3$, который успешно обрабатывает любую цепочку, которую успешно обрабатывает хотя бы один из $AVT1$, $AVT2$.

Любопытный читатель может спросить: а на кой это вообще все надо?

Ну во-первых, такое задание могут дать на экзамене.

А во-вторых, такое задание могут дать на экзамене в скрытой форме: вас могут попросить построить автомат, который принимает слова данной грамматики, но только четной длины.

Тогда можно построить 2 автомата: первый принимает слова данной грамматики, а второй - слова четной длины. После этого их можно пересечь и радоваться жизни.

6.1 Алгоритм

Все алгоритмы требуют, чтобы автоматы были полные. Поэтому если надо, дополняем их.

6.2 Отрицание


Тут все предельно просто - взяли полный автомат, в нем все состояния, которые не были конечными, сделали конечными. А все состояния, которые были конечными, сделали неконечными.

...



Ну вот в принципе и все.

Вот живой пример:

Взяли автомат



Дополнили и проотрицали




6.3 Почему это работает


Очевидно, что если цепочка принадлежит исходному языку, то автомат остановится в своем конечном состоянии. А если цепочка не принадлежит - в любом другом состоянии. Поэтому мы просто берем и меняем местами конечные и неконечные состояния. При этом полнота автомата необходима - ведь иначе мы потеряем часть слов, которые изначально не принадлежали старому языку, но принадлежат новому.

6.4 Пересечение и объединение

Здесь мы возьмем 2 следующих автомата:



Возьмем их дополненные версии:




Теперь все будет немножко сложнее. Для начала нужно построить прямое произведение двух автоматов.

Можно было бы привести "очень математическое" определение прямого произведения, но оно хоть и очень точное, но вообще не выразительное, поэтому будем объяснять на словах.

Прямое произведение автоматов очень понятно смотрится на фоне перемещения в двухмерном пространстве (ну или в n -мерном, если мы пересекаем n автоматов, но тут я могу понадеяться, что моему бедному читателю никогда не придется делать произведение больше 2х автоматов).

Очень удобно представлять, что первый автомат символизирует собой перемещение по оси OX , а второй - по OY . Начальное состояние - точка $(A, 1)$. По символу b по OX мы переходим в точку C , а по OY - в 2. В итоге мы находимся в точке $(C, 2)$. По символу a по OX мы переходим обратно в A , а по OY - обратно в 1. Дальше, допустим, нам прилетает символ a . По OX мы переносимся в точку B , а по OY остаемся в 1. А потом нам, например, прилетает символ b и по OX мы переносимся в C , а по OY - в 2.

На рисунке изображены символические перемещения в двухмерном пространстве.



Внимательный читатель мог заметить, что все эти перемещения напрямую связаны с автоматами, которые мы обрабатываем. По сути мы пытаемся усидеть на двух стульях, перемещаясь одновременно по двум автоматам.

И тут приходит в голову мысль: зачем нам постоянно помнить, что в первом автомате мы находимся в состоянии S , а во втором - в состоянии Q , если можно просто сделать вид, что автомат на самом деле один, а мы находимся в состоянии SQ . Если в первом автомате мы по символу a переходим в состояние P , а во втором - в состояние R , то мы просто вспоминаем, что автомат на самом деле один, а мы просто из SQ по a переходим в PR .

Давайте же построим произведение наших полных автоматов:

Это куда удобнее делать с помощью таблицы. Для начала нужно сделать таблицу для исходных автоматов:

	$a \quad b$			$a \quad b$	
A	B	C	1	1	2
B	B	C	*2	1	3
* C	A	V	3	3	3
V	V	V			

А теперь строим таблицу произведения (это очень скучно):

	$a \quad b$	
$A1$	$B1$	$C2$
$B1$	$B1$	$C2$
$C1$	$A1$	$V2$
$V1$	$V1$	$V2$
$A2$	$B1$	$C3$
$B2$	$B1$	$C3$
$C2$	$A1$	$V3$
$V2$	$V1$	$V3$
$A3$	$B3$	$C3$
$B3$	$B3$	$C3$
$C3$	$A3$	$V3$
$V3$	$V3$	$V3$

Это ВСЕ возможные сочетания состояний из первого и второго автомата. Но внимательный читатель мог заметить, что по факту нужны далеко не все (в силу того, что больше половины из них недостижимы). Действительно, учитывая, что начальное состояние это состояние состоящие из начальных состояний двух старых автоматов, а именно $A1$, достижимы только состояния $A1, B1, C2, V3$.


Поэтому вполне хватит такой таблицы:

	a	b
$A1$	$B1$	$C2$
$B1$	$B1$	$C2$
$C2$	$A1$	$V3$
$V3$	$V3$	$V3$

Остается вопрос: что же взять в качестве множества конечных состояний?

Вот тут уже зависит от задачи: если у нас пересечение, то мы берем состояние, состоящее только из конечных состояний старых автоматов (в данном случае $C2$).

Если же у нас объединение, то мы берем состояния, в составе которых есть хотя бы одно конечное состояние (в данном случае это могли бы быть $A2, B2, C2, V2, C1, C3$, но пример вышел неудачный и из достижимых осталось только $C2$, а подбирать другие автоматы слишком лень).



А получилось так потому, что второй автомат является сокращенной версией первого, но мне все еще слишком лень что-то переделывать.

6.5 Почему это работает

Саму концепцию произведения я вроде расписал через двухмерное пространство. Почему же мы именно так выбираем конечные состояния в случае пересечения и произведения?

Все просто: в случае пересечения нам надо, чтобы оба автомата остановились в своих конечных состояниях (потому что слово должно принадлежать обоим языкам). Соответственно, нам нужны состояния, состоящие из конечных состояний автоматов. Абсолютно аналогичная ситуация с объединением: нам нужно, чтобы хотя бы один из исходных автоматов остановился в своем конечном состоянии.

Глава 7


Построение автомата по праволинейной грамматике

7.1 Алгоритм

S - аксиома грамматики. Значит, начальное состояние у нас S . Множество конечных состояний F описывается так: если есть переход $S \rightarrow e$, тогда $F = \{S, R\}$, иначе $F = \{R\}$ (R это просто финальное состояние, такого терминала вообще в грамматике быть не должно)

Переходы строятся по следующим правилам:

$$A \rightarrow aB$$



$$A \rightarrow a$$



Возьмем такую грамматику:


$$S \rightarrow aA|bB|c$$

$$A \rightarrow aA|bB|cC$$

$$B \rightarrow bB|a|c$$

$$C \rightarrow aB|bC|cA$$

Построим автомат по правилам выше:



И что, все?

Ну да, все

7.2 Почему это работает

Праволинейные грамматики очень хороши хотя бы тем, что если раскручивать их, начиная с аксиомы S , мы ни в какой момент времени не сможем иметь больше одного необработанного нетерминала.

Очень похоже на автомат: там мы тоже всегда находимся в одном состоянии (если автомат один).

При этом правила вида $S \rightarrow aA$ говорят как бы следующее: мы разобрались с нетерминалом S , потому что увидели терминал a и все для себя поняли, теперь надо разбраться с нетерминалом A .

Это уже самый натуральный автомат, где состояние A соответстует нетерминалу A , который мы еще не успели раскрутить.

Глава 8

Приведение КС-грамматики

8.1 Алгоритм удаления бесплодных символов

Бесплодные символы - те, из которых невозможно вывести цепочку.

Алгоритм простой:

Строим множества

$$N_0 = \{\}$$

$$N_i = \{A; A \rightarrow a, a \in N_{i-1} \cup T^*\} \cup N_{i-1}$$

То есть, мы последовательно добавляем в новое множество то, из чего можно было бы вывести предыдущее. Все это надо повторять до стабилизации.

Рассмотри на примере:

$$S \rightarrow ABD|cAC$$

$$A \rightarrow a|C$$

$$B \rightarrow AB|BA|BD$$

$$C \rightarrow bC|aC|cA$$

$$D \rightarrow a|bB|c$$

$$N_0 = \{\}$$

$$N_1 = \{A, D\}, (A \rightarrow c, D \rightarrow a|c)$$

$$N_2 = \{A, C, D\}, (C \rightarrow cA)$$

$$N_3 = \{A, C, D, S\}, (S \rightarrow cAC)$$

$$N_4 = N_3$$

После этого нужно удалить все правила, которые были связаны с бесплодными символами.

$$S \rightarrow \cancel{ABD}|cAC$$

$$A \rightarrow a|C$$

$$\cancel{B \rightarrow AB|BA|BD}$$

$$C \rightarrow bC|aC|cA$$

$$D \rightarrow a|\cancel{bB}|c$$

8.2 Почему это работает

В данном случае мы просто идем с конца и смотрим, из чего мы могли бы вывести слово, состоящее только из терминальных символов. В конце остается множество тех нетерминалов, из которых можно вывести что-то годное. Соответственно, другие нам не нужны.

8.3 Алгоритм удаления недостижимых символов

Сразу скажу, что этот алгоритм есть смысл применять только после удаления бесплодных символов, потому что после этого алгоритма новые бесплодные символы появиться не могут, а после предыдущего новые недостижимые - легко.

Алгоритм простой:

Строим множества

$$V_0 = \{S\}$$

$$V_i = \{B; A \rightarrow aBb, A \in V_{i-1}, x, y \in T^*\} \cup V_{i-1}$$

То есть, мы последовательно добавляем в новое множество те нетерминалы, которые можно с помощью правил грамматики получить из предыдущего. Повторять до стабилизации.

Рассмотрим на примере, оставшегося после работы предыдущего алгоритма:

$$S \rightarrow cAC$$

$$A \rightarrow a|C$$

$$C \rightarrow bC|aC|cA$$

$$D \rightarrow a|c$$

$$V_0 = \{S\}$$

$$V_1 = \{S, A, C\}, (S \rightarrow cAC)$$

$$V_2 = V_1$$

Получили множество достижимых символов, осталось удалить все правила, связанные с недостижимыми.

$$S \rightarrow cAC$$

$$A \rightarrow a|C$$

$$C \rightarrow bC|aC|cA$$

$$\cancel{D \rightarrow a|c}$$

8.4 Почему это работает

Если в предыдущем алгоритме мы шли с конца, то в этом мы идеологически делаем ровно то же самое, только с начала.

Потому что это логично: зачем нам нетерминалы, которые никогда не смогут раскрыться в цепочку? (незачем)

8.5 Алгоритм удаления ϵ -правил

На самом деле избавиться от всех ϵ -правил не всегда возможно (если они уже есть), но можно свести все к единственному ϵ -правилу $S \rightarrow \epsilon$.

Алгоритм сложно описать без живого примера под рукой, поэтому сразу в бой:

$$S \rightarrow ABA|BAB$$

$$A \rightarrow a|e$$

$$B \rightarrow b|AaB|e$$

У нас 2 "плохих" нетерминала: A, B (потому что ни тот, ни другой не являются аксиомой грамматики, но имеют ϵ -правила).

Начнем с A . Мы удалим из него ϵ -правило, но все другие правила, где есть A , мы дополним альтернативами "что было бы, если бы A превратился в ϵ ":

$$S \rightarrow ABA|BA|AB|B|BAB|BB$$

$$A \rightarrow a$$

$$B \rightarrow b|AaB|aB|e$$

Теперь сделаем то же самое со вторым "плохим" нетерминалом: B .

$$S \rightarrow ABA|AA|BA|AB|A|B|BAB|BB|e$$

$$A \rightarrow a$$

$$B \rightarrow b|AaB|Aa|aB|a$$

8.6 Почему это работает

Потому что по сути мы просто расписываем все возможные варианты на случай если неприятный для нас нетерминал превратится в ϵ . Тут алгоритм говорит сам за себя.

8.7 Алгоритм удаления левой рекурсии (примитивной)

Этот алгоритм удаляет левую рекурсию глубины 1. Как удалять левую рекурсию произвольной глубины не поняла даже сама Таня (с конспектов которой сдувается эта методичка), поэтому максимум, что мы можем, это молиться, чтобы у нас такого не было.

Левая рекурсия, это когда есть правила вида $A \rightarrow Aa|b$. Удаляется она так:

Правила вида

$$A \rightarrow Aa_1|Aa_2|\dots|Aa_n|b_1|b_2|\dots|b_m$$

Переходят в наборы правил вида:

$$A \rightarrow b_1A^*|b_2A^*|\dots|b_mA^*$$

$$A^* \rightarrow a_1A^*|a_2A^*|\dots|a_nA^*|e \quad \text{!!!ВАЖНО не забыть про } e \text{ в конце.}$$

Рассмотрим на примере:

$$S \rightarrow Sa|Sb|c$$

$$A \rightarrow Ac|b$$

Все это легким движением руки превращается в

$$S \rightarrow cS^*$$

$$S^* \rightarrow aS^*|bS^*|e$$

$$A \rightarrow bA^*$$

$$A^* \rightarrow cA^*|e$$

8.8 Почему это работает

Чтобы лучше это понять для начала надо понять, какой язык получается из такого правила

$$A \rightarrow Aa_1|Aa_2|\dots|Aa_n|b_1|b_2|\dots|b_m$$

Наблюдательный читатель может заметить, что слова в этом языке по-любому будут начинаться на один из символов из $\{b_1\dots b_m\}$. При этом символ из множества $\{b_1\dots b_m\}$ встретится только один раз (допуская, что символы $\{a_1\dots a_n\}$ не пересекаются с $\{b_1\dots b_m\}$). После первого символа идет произвольное число символов из $\{a_1\dots a_n\}$.

Переделав наше старое правило в два новых

$$A \rightarrow b_1A^*|b_2A^*|\dots|b_mA^*$$

$$A^* \rightarrow a_1A^*|a_2A^*|\dots|a_nA^*|e$$

мы первым правилом реализуем начало на любой символ из $\{b_1\dots b_m\}$, а вторым - реализуем множество произвольной длины из символов $\{a_1\dots a_n\}$.

А если языки совпадают, то должно ли нас волновать, что правила записаны по-разному? (нет)

8.9 Алгоритм удаления левой факторизации

Левая факторизация, это когда у нас есть множество "мусорных правил" у которых совпадают префиксы.

Ошарашенный читательно может сильно нахмуриться от такой стремной фразы, поэтому куда понятнее все будет смотреться на примере:

$$A \rightarrow ab_1|ab_2|\dots|ab_m|\dots|c$$

Это левая факторизация. Бесит она тем, что грамматику все время хочется привести к автомату, а из-за неоднозначности, это не очень хорошо получается.

Поэтому эти терминалы надо просто разнести. Вот так:

$$A \rightarrow aA^*|\dots|c$$

$$A^* \rightarrow b_1|b_2|\dots|b_m$$

8.10 Почему это работает

По той же причине, по которой работало удаление левой рекурсии: языки совпадают. Здесь совпадение языков настолько очевидно, что я даже не возьмусь объяснить, почему они совпадают.

Поэтому если это не очень очевидно, ну попробуйте погонять первый вариант правила, и второй: если сможете построить на их основе разные языки, напишите об этом сюда info@fskn.gov.ru

Глава 9

Построение LL(1)-анализатора

Сразу есть смысл сказать, что этот LL(1)-анализатор полностью списан из инструкций от Тани, просто здесь, наверное, будет побольше письменных описаний, а у нее будут очень удобные схемы. Поэтому советую эту тему рассматривать совместно с первоисточником.

LL(1)-анализатор это такая штука, которая умеет довольно быстро и эффективно работать с цепочками языка, который задается определенного вида грамматиками.

Чтобы по грамматике можно было построить LL(1)-анализатор, нужно:

- 1) Чтобы грамматика была нелеворекурсивна
- 2) Чтобы грамматика была однозначна

В противном случае удаляем левую рекурсию и, соответственно, факторизацию.

Теперь надо ввести 2 уже немного знакомых нам понятия:

$FIRST(\alpha)$ - множество терминалов с которых может начинаться цепочка α .

$FOLLOW(\alpha)$ - множество терминалов, которые могут следовать после цепочки α .

В обоих случаях α - это цепочка из терминальных и нетерминальных символов, но при раскрытии нетерминалов могут образовываться самые разные терминалы, поэтому тут надо быть аккуратным.

Также грамматика должна удовлетворять следующему условию:

Если в грамматике есть правило вида $A \rightarrow \alpha | \beta$, то

- 1) $FIRST(\alpha) \cap FIRST(\beta) = \emptyset$
- 2) Если $e \in FIRST(\alpha)$, то $FIRST(\beta) \cap FOLLOW(A) = \emptyset$ обращаю отдельное внимание, что здесь у нас не $FOLLOW(\alpha)$, а $FOLLOW(A)$.

Оба эти правила нацелены на одну вещь: чтобы мы всегда могли по терминальному символу определить, какое правило грамматики нам надо применять сейчас.

Начинаем строить *FIRST* и *FOLLOW* для всех нетерминалов грамматики. Тут как и в построении ДКА по РВ довольно неплохо работает здравый смысл, но есть и строгие правила:

FIRST:

$$a \in T \Rightarrow FIRST(a) = \{a\}$$

$$A \rightarrow BC \Rightarrow FIRST(B) \in FIRST(A)$$

$$A \rightarrow \alpha\beta, e \in FIRST(\alpha); \Rightarrow FIRST(\beta) \in FIRST(A) \quad \text{этого правила не было в конспектах Тани, но мне кажется, что оно получается из здравого смысла}$$

FOLLOW:

Для начала проинициализируем $\# \in FOLLOW(S)$ ($\#$ - символ конца строки, S - аксиома грамматики)

$$A \rightarrow \alpha B \beta, \beta \in (N \cup T)^*; \Rightarrow \text{добавим } FIRST(\beta) \setminus \{e\} \text{ в } FOLLOW(B)$$

$$A \rightarrow \alpha B \text{ или } A \rightarrow \alpha B \beta, \beta \Rightarrow^* e; \Rightarrow \text{добавим } FOLLOW(A) \text{ в } FOLLOW(B)$$

Мне кажется, что все правила построения очень тяжело описать, а формальные определения тут не помогут совсем, поэтому очень-очень советую пользоваться методом пристального взгляда при построении множеств.

Рассмотрим на примере:

$$S \rightarrow aS^*$$

$$S^* \rightarrow AbC|bC|e$$

$$C \rightarrow BS^*|S^*$$

$$A \rightarrow aA^*$$

$$A^* \rightarrow a|b$$

$$B \rightarrow c$$

Таблица для *FIRST(N)*

$$S \quad a = a$$

$$S^* \quad b, e, FIRST(A) = a, b, e$$

$$C \quad FIRST(B), FIRST(S^*) = a, b, c, e$$

$$A \quad a = a$$

$$A^* \quad a, b = a, b$$

$$B \quad c = c$$

Таблица для *FOLLOW(N)*

$$S \quad \#, FOLLOW(S^*) = \#$$

$$S^* \quad FOLLOW(S), FOLLOW(C) = \#$$

$$C \quad FOLLOW(S^*) = \#$$

$$A \quad b, FOLLOW(A^*) = b$$

$$A^* \quad FOLLOW(A) = b$$

$$B \quad FIRST(S^*) \setminus e = a, b$$

Теперь надо построить таблицу анализатора M . Но перед этим нужно взять нашу грамматику и пронумеровать все правила.

$S \rightarrow aS^*$	1
$S^* \rightarrow AbC bC e$	2, 3, 4
$C \rightarrow BS^* S^*$	5, 6
$A \rightarrow aA^*$	7
$A^* \rightarrow a b$	8, 9
$B \rightarrow c$	10

Теперь для всех правил $A \rightarrow \alpha$ (напомню, что у каждого правила есть номер n) проделываем следующее:

$$a \in FIRST(\alpha) \Rightarrow M[A, a] = n$$

$$e \in FIRST(\alpha) \text{ и } b \in FOLLOW(A) \Rightarrow M[A, b] = n$$

На основе всего этого получаем таблицу для нашего анализатора:

	a	b	c	$\#$
S	1			
S^*	2	3		4
C	6	6	5	6
A	7			
A^*	8	9		
B			10	

9.1 Почему это работает

Благодаря ограничениям, наложенным на грамматику, мы можем достаточно простым способом (это вам не LR-анализ) получить анализатор, который разбирает цепочку без возвратов. Все, что ему нужно знать - это какой нетерминал он сейчас разбирает и какой терминальный символ сейчас крайний в разбираемой цепочке. Благодаря однозначности (нет такой ситуации, что мы разбираем нетерминал Q , нам прилетает терминал x , а мы не понимаем, относится ли он к Q , или не относится) мы можем просто идти по таблице анализатора и выполнять правила, которые там записаны.

Реально алгоритм сияет при разборе цепочки. Все ограничения, введенные для LL анализатора, сразу становятся понятными (или почти понятными), когда с помощью анализатора разбирается цепочка. Чем мы сейчас и займемся.

9.2 Алгоритм разбора цепочки с помощью LL(1)-анализатора

Начинается все с магазина в котором аксиома грамматики и символ конца $\#$.

$$S\# \quad | \quad a_1 a_2 \dots a_n \#$$

Пусть A - первый символ магазина, a - первый символ разбираемой строки.

Тогда действом по правилам:

- 1) $A = a = \# \Rightarrow \text{Accept}$ строка успешно разобрана
- 2) $A = a \neq \# \Rightarrow$ убираем A и a
- 3) $A \in T$ (терминальный символ), $A \neq a \Rightarrow \text{Error}$ строка не принадлежит языку.
- 4) $A \in N$ применяем к магазину слева правило $M[A, a]$

Рассмотрим на живом примере:

$S\#$	$ $	$abcb\#$	$M[S, a] = 1$
$aS^*\#$	$ $	$abcb\#$	$a = a \rightarrow \text{Drop}$
$S^*\#$	$ $	$bc b\#$	$M[S^*, b] = 3$
$bC\#$	$ $	$bc b\#$	$b = b \rightarrow \text{Drop}$
$C\#$	$ $	$cb\#$	$M[C, c] = 5$
$BS^*\#$	$ $	$cb\#$	$M[B, c] = 10$
$cS^*\#$	$ $	$cb\#$	$c = c \rightarrow \text{Drop}$
$S^*\#$	$ $	$b\#$	$M[S^*, b] = 3$
$bC\#$	$ $	$b\#$	$b = b \rightarrow \text{Drop}$
$C\#$	$ $	$\#$	$M[C, \#] = 6$
$S^*\#$	$ $	$\#$	$M[S^*, \#] = 4$
$\#$	$ $	$\#$	$\# = \# \rightarrow \text{Accept}$

Глава 10

Построение LR(1)-анализатора по КС-грамматике

Глава 11

Лемма о накачке